

보행 보조용 분할 모델 실험 보고서

YOLO11s-seg × Foundation Model (C-RADIOv3) — 성능, 추론 속도, 오류 원인 분석
Team Insight · detection 브랜치 · 2026-10-04

한눈에 보기

질문	답
무엇을 했나	보행 영상 분할 모델 YOLO11s-seg 에 Foundation Model 인코더 C-RADIOv3 를 붙이면(A5) 성능과 속도가 어떻게 되는지, 붙이지 않은 기본 모델(E0)과 비교
성능	mask mAP50-95 E0 0.308 → A5 0.331 (+0.023) . 10개 클래스 중 9개에서 A5가 높음
속도 (GPU)	실제 이미지 1장 처리 E0 13.4ms (75 FPS) → A5 22.5ms (44 FPS) . 둘 다 실시간 가능
속도 (CPU)	E0 0.29초 → A5 2.87초 (약 10배). CPU에서는 A5를 실시간으로 쓸 수 없음
점수가 낮은 이유	① 정답 라벨이 빠진 물체를 맞게 찾아도 오답 처리 ② 아주 작은 물체 ③ scooter 데이터 부족 ④ stairs 원본 라벨 오류
다음 할 일	노트북 CPU에서 속도 실측 → stairs 재라벨링 → scooter 데이터 보강

1. 실험 구성

모델	구성	추론 시 사용
E0	YOLO11s-seg (COCO 사전학습)	YOLO만
A5	YOLO11s-seg + C-RADIOv3-B 특징을 백본에 더함 (fusion)	YOLO + C-RADIOv3


항목	내용
데이터	AI Hub 「인도보행 영상」, 10개 클래스
학습	scooter-stairs-traffic_light가 들어간 train 사진 전부 8,120장 . 다른 클래스도 이 사진들에 함께 들어 있음
평가	학습에 한 번도 쓰지 않은 test 13,721장
학습 길이	E0 100 epoch (가장 좋았던 시점: 73), A5 70 epoch 설정 → 61에서 자동 종료 (가장 좋았던 시점: 56)
장비	NVIDIA RTX A5000 (24GB)

클래스 (10개): person, bicycle, scooter, motorcycle, car, bus, other_vehicle(트럭·손수레·유모차·휠체어), obstacle(기둥·나무·볼라드 등 15종), stairs, traffic_light

2. 데이터

항목	값
라벨된 사진	92,772장 (영상 1,955개)
라벨된 물체	581,529개 (사진당 평균 6.3개)
분할	영상 단위로 train 64,952 / val 14,099 / test 13,721장 (같은 영상이 train과 test에 섞이지 않음)
카메라	스마트폰 57% (가슴 높이 추정), ZED 스테레오 43% (허리~가슴 높이 추정)


"물체 수"와 "사진 수"는 다르다. 신호등 3개가 찍힌 사진 1장은 물체 3개, 사진 1장으로 센다.



클래스	물체	사진	학습(train) 사진	평가(test) 물체
obstacle	293,918	82,745	57,977	43,540
car	147,131	55,957	39,117	22,566
person	47,192	26,149	18,008	7,174
other_vehicle	35,379	21,516	14,984	5,317
traffic_light	26,796	11,106	7,750	4,193
bus	11,321	6,484	4,331	1,978
bicycle	10,003	6,581	4,566	1,600
motorcycle	9,039	6,731	4,692	1,394
stairs	399	372	247	79
scooter	351	224	144	94

작은 물체가 많다. 640px 화면 기준으로 traffic_light는 89%, obstacle은 48%가 짧은 변 16px 미만이다.


클래스별 객체 크기 분포 (small < 32², medium < 96², 640×360 기준)



클래스별 물체 크기

3. 성능 결과

클래스	E0	A5	차이
car	0.577	0.586	+0.009
person	0.437	0.463	+0.026
bus	0.390	0.428	+0.038
other_vehicle	0.379	0.414	+0.035
obstacle	0.363	0.376	+0.013
motorcycle	0.302	0.378	+0.075
bicycle	0.209	0.236	+0.027
stairs	0.219	0.210	-0.009
traffic_light	0.165	0.176	+0.011
scooter	0.037	0.040	+0.003
전체 (mask mAP50-95)	0.308	0.331	+0.023
전체 (mask mAP50)	0.534	0.568	+0.034



클래스별 성능

- C-RADIOv3를 붙이면 거의 모든 클래스에서 오른다. 특히 motorcycle, bus, other_vehicle.
- stairs, scooter, traffic_light는 두 모델 모두 낮다. 모델보다 데이터 문제다 (5장).



학습 곡선

A5는 처음부터 E0보다 점수가 높고 더 빨리 최고점에 도달한다. E0은 73 epoch 이후 과적합이 시작되지만, 평가에는 가장 좋았던 시점의 모델을 썼으므로 결과에는 영향이 없다.


4. 추론 속도

학습이 끝난 뒤 GPU가 빈 상태에서 모델을 하나씩 측정했다 (640×640, 이미지 1장씩).

추론 속도: GPU에서는 1.7배, CPU에서는 약 10배 느려짐

GPU (A5000) 실제 이미지 1장 처리

CPU 4스레드, 모델 1장



항목	E0	A5	배수
GPU, 실제 이미지 1장 (전처리+추론+후처리)	13.4 ms (75 FPS)	22.5 ms (44 FPS)	1.7배
GPU, 모델 계산만 (FP16)	11.1 ms	21.1 ms	1.9배
CPU 4스레드, 모델 계산만	294 ms (3.4 FPS)	2,867 ms (0.35 FPS)	9.8배
CPU 8스레드, 모델 계산만	195 ms	1,615 ms	8.3배
파라미터 수	1,010만	1억 830만	10.7배
연산량 (1장)	33 GFLOPs	408 GFLOPs	12.4배

- A5의 GPU 시간 중 절반(10.1ms)이 C-RADIOv3 인코더다.
- GPU에서는 A5도 44 FPS로 실시간 처리가 된다.
- CPU에서는 A5가 1초에 1장도 처리하지 못한다. 노트북 CPU에서 돌려야 한다면 E0만 현실적이며, E0도 OpenVINO 변환이 필요하다.
- CPU 수치는 서버 CPU의 스레드 수를 제한해 낸 값이다. 실제 노트북에서는 다를 수 있어 다시 재야 한다.

5. 점수가 낮은 이유

test 전체에서 정답 물체 하나하나를 모델이 찾았는지, 모델이 찾은 것이 정답이었는지를 확인했다 (기준: 확신도 0.25 이상, 위치 겹침 50% 이상).


클래스	찾은 비율 (recall)	찾은 것 중 맞은 비율 (precision)
car	83%	73%
traffic_light	79%	47%
person	75%	78%
obstacle	65%	66%
other_vehicle	58%	65%
stairs	43%	30%
scooter	36%	10%

① 정답 라벨이 빠진 물체를 맞게 찾아도 오답이 된다

모델이 "오답"으로 처리된 예측을 직접 보면, 상당수가 실제로 맞는 물체인데 정답 라벨이 없는 경우다.

- **obstacle:** 라바콘, 고가 기둥, 벤치, 분전함, 입간판 (라바콘은 AI Hub 원본 라벨 종류에 아예 없음)

obstacle: false positives, top 40 conf of 14844




- **traffic_light:** 라벨이 안 된 신호등 옆면·뒷면, 횡단보도 표지판

traffic_light: false positives, top 40 conf of 3787



→ 실제 성능은 숫자보다 좋다. 정확히 재려면 test 라벨을 보완해야 한다.

② 아주 작은 물체는 못 찾는다




- car와 person은 16px 이상이면 80~97%를 찾지만, 8px 이하는 16~26%만 찾는다.
- traffic_light는 위치는 잘 찾는다(8px 이하도 75%). 하지만 4~8px 물체는 윤곽(마스크)이 1~2px만 어긋나도 점수가 크게 깎여서 mask 점수가 낮다.
- → 입력 해상도를 960~1280px로 올리면 직접 좋아질 부분이다.

③ scooter: 데이터가 너무 적고, 오토바이·자전거와 헷갈린다

- 학습 사진이 **144장**뿐이다 (motorcycle 476장, bicycle 593장).
- scooter라고 잘못 부른 것의 절반(49%)이 **오토바이·자전거·사람** 위에 있다. 나머지는 손수레·유모차·어린이 탈것이다.
- test 정답이 94개뿐이라 점수 자체도 크게 흔들린다.
- → 모델을 바꿔도 안 된다 (A5도 0.040). **scooter 데이터를 늘려야 한다.**

scooter: false positives, top 40 conf of 312



scooter 오답 예시

④ stairs: 원본 라벨이 틀렸다

stairs 라벨은 전부 Surface 데이터(S1.zip)에서 왔다. 원본 라벨을 원본 이미지에 그려 보면 실제 계단은 3분의 1 정도이고, 나머지는 가로수 보호판.맨홀.연석에 stairs가 붙어 있다. 보행 영상(Polygon)에는 계단 라벨이 아예 없어서, 거기 찍힌 계단은 배경으로 학습된다.



stairs 원본 라벨 (빨간 선)


→ 재라벨링이 먼저다. 372장이란 몇 시간이면 된다.

원인이 아닌 것

- **흐림**: 흐린 물체 0.2% (대부분 야간 장면)
- **조명**: 어두운 프레임 0.4%. "어두운 물체"는 대부분 원래 색이 검은 기둥
- **화면 밖으로 잘림**: 잘린 물체를 오히려 더 잘 찾음 (잘린 것은 대부분 큰 물체)
- **카메라 종류**: 스마트폰과 ZED의 차이가 작음

6. 참고: 1차 pilot (인코더 비교)

본 실험 전에, 적은 데이터(사진 996장, 30 epoch)로 인코더 8종을 두 방식으로 비교했다.



- **fusion** (추론에도 인코더 사용): 8개 모두 E0보다 상승 (+0.03 ~ +0.07)
- **distill** (학습에만 인코더 사용, 추론은 YOLO만): 8개 모두 효과 없음 (± 0.008)
- 그래서 최종 실험은 fusion 중 **상업 이용이 가능하면서 가장 빠른 C-RADIOv3 (A5)** 로 진행했다.

7. 결론과 다음 할 일

	판단
✅ C-RADIOv3 fusion	성능이 오른다 (+0.023, 9/10 클래스)
✅ GPU 실시간	E0 75 FPS, A5 44 FPS 모두 가능
❌ CPU에서 A5	2.9초/장, 실시간 불가
❌ distill	효과 없음
⚠️ 평가 점수	라벨 누락 때문에 실제보다 낮게 나옴
❌ stairs / scooter / traffic_light	라벨 오류 / 데이터 부족 / 작은 물체

다음 할 일 (우선순위)

1. 실제 사용할 노트북 CPU에서 E0-A5 속도 실측 (OpenVINO 포함) → A5를 쓸지 결정
2. stairs 재라벨링 (372장)
3. scooter 데이터 추가
4. test 라벨 보완 (라바콘·신호등 뒷면 등)
5. traffic_light 개선을 위해 입력 해상도 960~1280px 실험

부록: 파일 위치

무엇	어디
상세 인수인계 문서 (재현 방법, 겪은 문제 등)	HANDOVER.md (GitHub detection 브랜치)
최종 결과·속도·오류 분석 원본	insight_fm/analysis/final/
데이터 분석	insight_fm/analysis/data_analysis.md, insight_fm/analysis/objects/object_quality.md
최종 모델 가중치	Google Drive sideguide/runs_final10/<E0_s0, A5_s0>/weights/best.pt
코드	insight_fm/ (setup.sh → run_all.py, 최종 실행 tools/run_final10.sh)